

基于 20 Newsgroups 的 NLP 课后作业报告

项目	内容
数据集	20 Newsgroups (Scikit-learn 内置)
工具	Python、Pandas、Matplotlib/Seaborn、Scikit-learn、NLTK
代码	<code>run_homework.py</code> 、 <code>newsgroups_nlp_homework.ipynb</code>

一、作业目的

掌握英文新闻组文本分类的完整流程：数据加载与清洗、文本预处理、词袋/TF-IDF 特征表示、多项式朴素贝叶斯分类，并对比不同特征与模型效果。

二、任务 1：数据加载与探索

2.1 选定类别（4 类）

类别	含义
comp.graphics	计算机图形
sci.space	太空科学
rec.sport.baseball	棒球运动
talk.politics.misc	政治杂谈

四类分属不同主题域，便于检验分类器区分能力。

2.2 加载方式

使用 `sklearn.datasets.fetch_20newsgroups`，参数：

```
remove=("headers", "footers", "quotes") # 剔除邮件头、页脚、引用
```

2.3 基本信息

项目	数值
文档总数	3729
类别数	4

2.4 各类样本数量分布

类别	样本数
comp.graphics	973
rec.sport.baseball	994
sci.space	987
talk.politics.misc	775

分布略有不均但可分层抽样，详见 `output/task1_class_distribution.csv`。

三、任务 2：文本预处理

对每篇文档依次执行：

1. 转小写
2. 去除标点与数字（仅保留 a-z）
3. 简单分词（按空白切分）
4. 去除英文停用词（`sklearn.feature_extraction.text.ENGLISH_STOP_WORDS`）

预处理示例

阶段	文本片段
原文	Are you kidding? I'm stuck with the Toronto SkyDome...
处理后	kidding stuck toronto skydome idea th inning stretch blue jays...

四、任务 3：特征表示与数据划分

特征方式	说明
CountVectorizer	词袋模型（词频）
TfidfVectorizer	TF-IDF 加权

- 在预处理后的空格分词文本上向量化，`max_features=20000`，`min_df=2`
- 训练集：测试集 = 7：3（`stratify` 分层抽样）
- 训练 2610 条，测试 1119 条；特征维度约 13925

五、任务 4：多项式朴素贝叶斯分类结果

5.1 测试集准确率

特征	准确率
词袋 (Count)	0.8937
TF-IDF	0.8990

TF-IDF 略高 +0.53 个百分点。

5.2 混淆矩阵 (词袋)

真实 \ 预测	comp.graphics	rec.sport.baseball	sci.space	talk.politics.misc
comp.graphics	265	12	9	6
rec.sport.baseball	4	287	0	7
sci.space	9	27	240	20
talk.politics.misc	2	16	7	208

5.3 混淆矩阵 (TF-IDF)

真实 \ 预测	comp.graphics	rec.sport.baseball	sci.space	talk.politics.misc
comp.graphics	280	7	4	1
rec.sport.baseball	6	286	3	3
sci.space	16	24	252	4
talk.politics.misc	4	24	17	188

可视化见：[figures/cm_nb_bow_4class.png](#)、[figures/cm_nb_tfidf_4class.png](#)。

5.4 主要观察

- **rec.sport.baseball** 召回率最高 (词袋 0.96, TF-IDF 0.96)，体育术语区分度好。
- **sci.space** 与 **talk.politics.misc** 偶发混淆 (科学 vs 政治词汇交叉较少但仍存在误分)。
- **talk.politics.misc** 在 TF-IDF 下精确率更高 (0.96)，但召回略降。

六、任务 5：词袋 vs TF-IDF 对比分析

1. **共同点**：均将文本表示为稀疏高维向量，符合多项式朴素贝叶斯的“词频计数”假设。
2. **词袋**：只统计词频，常见词 (如 say、people) 权重过大，可能削弱主题词。
3. **TF-IDF**：对全语料高频词降权、对特定类高频词加权，更突出 **comp / sci / rec / talk** 的主题差异。
4. **本实验**：TF-IDF 准确率 0.8990 > 词袋 0.8937，符合多数文本分类经验；二者差距不大，说明 4 类主题本身区分度较高。
5. **结论**：推荐默认使用 **TF-IDF + 多项式朴素贝叶斯** 作为基线方案。

七、选做拓展

7.1 全部 20 类多分类

特征	准确率
词袋 + NB	0.6885
TF-IDF + NB	0.7195

类别从 4 增至 20 后，相似子类（如 comp.sys.ibm.pc.hardware vs comp.sys.mac.hardware）增多，准确率明显下降，符合预期。

7.2 词干 / 词形还原 (TF-IDF + NB, 4 类)

预处理	准确率
基础	0.8990
词干还原 (Porter)	0.9062
词形还原 (WordNet)	0.9026

词干还原带来约 **0.7%** 提升，将不同形态归并（如 game/games），特征更紧凑；词形还原略优但计算更重，收益有限。

7.3 模型对比 (TF-IDF, 4 类)

模型	准确率
MultinomialNB	0.8990
LogisticRegression	0.8945
LinearSVC	0.9044

线性 SVM 略优；朴素贝叶斯训练最快、可解释性好；逻辑回归居中。三者差距 < 1%，说明特征质量对结果影响大于算法细微差别。

八、总结

- 成功完成 4 类新闻组文本分类流水线，剔除 headers/footers/quotes 后数据干净可用。
- TF-IDF** 略优于词袋；**词干还原**可小幅提升；**20 类**任务难度显著高于 4 类。
- 朴素贝叶斯、逻辑回归、线性 SVM 在 TF-IDF 特征上均达到约 **89% ~ 90%** 准确率，满足要求。

九、提交清单

文件	说明
<code>run_homework.py</code>	主程序（含每步 print 输出）
<code>newsgroups_nlp_homework.ipynb</code>	Notebook

文件	说明
作业报告.md	本报告
output/*.csv	数值结果
figures/*.png	混淆矩阵图

运行方式

```
conda activate ml
cd d:\OUC_machine_learning\w4-homework-20newsgroup
pip install -r requirements.txt
python run_homework.py
```

参考文献

1. Lang, K. (1995). Newsweeder: Learning to filter netnews. ICML.
2. Scikit-learn: fetch_20newsgroups documentation.
3. Manning et al. Introduction to Information Retrieval (TF-IDF, Naive Bayes).