

中国海洋大学工程实训

机器学习课程 · Week2 作业报告

商场客户聚类分析与营销策略

项目	内容
数据集	Mall_Customers.csv
工具	Python、Pandas、Matplotlib/Seaborn、Scikit-learn
姓名	刘静洹
学号	22090032021
完成日期	2026 年 5 月

一、作业目的

利用商场客户数据，通过**探索性数据分析（EDA）**与**K-Means 聚类**将客户划分为若干具有业务含义的群体，进而完成**客户画像与差异化营销策略**设计。本报告对应作业要求的五项任务：数据探索、特征选择与聚类、分群画像、营销建议及总结，代码与图表存放于 `week2/` 目录。

二、数据探索（任务 1）

2.1 数据加载与规模

项目	结果
样本量	200 条
字段数	5 列
文件	<code>Mall_Customers.csv</code>

字段名	含义	类型
CustomerID	客户编号	整数
Gender	性别 (Male/Female)	分类
Age	年龄	数值
Annual Income (k\$)	年收入 (千美元)	数值
Spending Score (1-100)	消费评分 (1-100)	数值

2.2 缺失值与异常值

- **缺失值**：各字段均为 0，数据完整，无需插补。
- **异常值 (IQR 法)**：Age 无异常；Spending Score 无异常；Annual Income 检出 2 条离群点（高端收入客户），属真实业务现象，聚类时保留。

2.3 描述统计摘要

变量	均值	标准差	最小	最大
Age	38.9	13.9	18	70
Annual Income (k\$)	60.6	26.3	15	137
Spending Score	50.2	25.8	1	99

- **性别**：Female 112 人 (56%)，Male 88 人 (44%)，略偏女性。
- **收入与消费评分**：整体呈较分散分布，为后续二维聚类提供区分度。

2.4 可视化 (EDA)




图 1 年龄、年收入、消费评分分布（左：年龄近正态；收入右偏；消费评分较均匀）。




图 2 性别比例及按性别划分的年龄、消费评分箱线图。




图 3 年收入与消费评分箱线图，可见收入与消费离散程度较大。




图 4 年收入—消费评分散点图显示客户自然形成多团块，适合聚类；性别在两维度上差异不极端。




图 5 年龄与消费评分略负相关 (-0.33)，收入与消费评分相关性弱，故聚类以收入 + 消费评分为主特征合理。

三、特征选择与聚类过程（任务 2）

3.1 特征选择

依据作业要求，选取二维关键特征：

- **Annual Income (k\$)**：购买力
- **Spending Score (1-100)**：消费意愿与活跃度

聚类前对两特征进行 **StandardScaler** 标准化，消除量纲影响。

3.2 确定聚类数：手肘法 + 轮廓系数

k	惯性 (Inertia)	轮廓系数 (Silhouette)
4	108.92	0.494
5	65.57	0.555
6	55.06	0.540




图 6 左图：k 从 4 增至 5 时惯性下降明显（“肘部”）；右图：在作业建议的 $k=4 \sim 6$ 区间内， $k=5$ 轮廓系数最高 (0.555)，故选定 5 类。

3.3 K-Means 建模与标签

- 算法： `kMeans(n_clusters=5, random_state=42, n_init=10)`
- 为每条客户打上标签 `cluster`：0、1、2、3、4
- 带标签数据： `output/Mall_Customers_clustered.csv`





图 7 五类客户在「收入—消费」平面上呈典型五象限分布，黑色 X 为簇中心。

四、客户分群画像（任务 3）

4.1 各群统计指标

客群	人数	平均年龄	平均年收入 (k\$)	平均消费评分	男性%	女性%
0	81	42.7	55.3	49.5	40.7	59.3
1	39	32.7	86.5	82.1	46.2	53.8
2	22	25.3	25.7	79.4	40.9	59.1
3	35	41.1	88.2	17.1	54.3	45.7
4	23	45.2	26.3	20.9	39.1	60.9



4.2 文字画像（是谁、特点、消费行为）

客群 0 — 中等稳健型（81 人，占比最大）

- **是谁：**年龄约 43 岁，收入与消费均接近全样本中等水平，女性略多。
- **特点：**消费习惯稳定，既不极端节俭也不冲动高消费。
- **消费行为：**常规到店、理性选购，对会员积分与组合优惠有响应，是商场**基本盘**。

客群 1 — 富裕积极型（39 人）

- **是谁：**平均年龄 33 岁，**高收入（86.5k\$）**、**高消费评分（82.1）**。
- **特点：**年轻高净值、消费意愿强。
- **消费行为：**偏好品质与体验，对新品、联名、VIP 服务敏感，**客单价与复购潜力最高**。

客群 2 — 潜力活跃型（22 人）

- **是谁：**平均年龄 **25 岁**，收入低（25.7k\$）但消费评分高（79.4）。
- **特点：**典型“低收入高花费”年轻人。
- **消费行为：**冲动消费、社交驱动，对折扣、快闪、积分活动敏感。

客群 3 — 富裕谨慎型（35 人）

- **是谁：**平均年龄 41 岁，**收入最高（88.2k\$）**但**消费评分最低（17.1）**。
- **特点：**购买力强但消费克制，理性、注重性价比或品牌信任。
- **消费行为：**到店频率可能不低，但单笔消费谨慎，需**权益与信任**激活。

客群 4 — 普通节约型 (23 人)

- **是谁：**平均年龄 45 岁，低收入（26.3k\$）、低消费（20.9）。
- **特点：**价格敏感、注重实用。
- **消费行为：**促销日、基础款、便民服务更能吸引到店。

五、营销策略（任务 4）

客群 0 — 中等稳健型

项目	内容
定位	中等收入、中等消费的稳定客群
建议 1	分级会员礼遇 + 生日月双倍积分
理由 1	习惯稳定，持续积分与等级权益可提升复购。
建议 2	家居、服饰等生活品类跨柜组合优惠
理由 2	客单价适中，组合促销可提高单次消费件数。

客群 1 — 富裕积极型

项目	内容
定位	高净值高消费核心客群
建议 1	VIP 私人导购与新品预览会
理由 1	重视尊贵体验，专属服务提升客单价与粘性。
建议 2	奢侈/轻奢品牌限定联名
理由 2	高消费意愿匹配高端联名，强化认同。

客群 2 — 潜力活跃型

项目	内容
定位	年轻高活跃、价格敏感型
建议 1	会员积分翻倍 + 快闪/网红打卡
理由 1	收入有限但爱消费，社交与积分驱动到店。
建议 2	学生活动日、第二件半价
理由 2	对折扣响应强，短期促销拉客流。

客群 3 — 富裕谨慎型

项目	内容
定位	高收入低消费的理性客群
建议 1	高额满减券（满额可用）+ 保价承诺
理由 1	降低决策顾虑，撬动沉睡购买力。
建议 2	家庭套装 / 品质生活馆场景陈列
理由 2	强调实用与品质，提高连带率。

客群 4 — 普通节约型

项目	内容
定位	大众基础消费客群
建议 1	每周特价日 + 基础款组合包
理由 1	价格导向，明码低价最易转化。
建议 2	免费停车/接驳 + 社区便民服务
理由 2	低成本权益培养习惯性到店。

六、总结（任务 5）

1. **数据质量**：

200 条客户记录完整无缺失，收入与消费评分分布适合聚类；收入存在少量高端离群点，属正常结构。
2. **聚类结论**：

在年收入与消费评分二维空间上，**K-Means (k=5)** 轮廓系数在建议区间内最优，将客户划分为中等稳健、富裕积极、潜力活跃、富裕谨慎、普通节约五类，与经典商场客户细分理论一致。
3. **业务价值**：

最大群体为**客群 0（中等稳健，81 人）**，应通过会员运营稳住基本盘；**客群 1** 贡献高端消费，**客群 2** 代表年轻增量，**客群 3** 需激活高净值低消费客户，**客群 4** 靠促销与便利引流。
4. **局限与展望**：

未纳入年龄、性别进入聚类特征；可尝试 DBSCAN、层次聚类对比；营销效果需 A/B 测试验证。

七、提交材料清单

文件	说明
工程实训作业报告_week2.md / PDF	本报告
mall_customer_clustering.ipynb	Jupyter 代码
run_analysis.py	运行脚本
Mall_Customers.csv	原始数据

文件	说明
output/Mall_Customers_clustered.csv	带 Cluster 标签数据
output/cluster_profiles.csv	分群统计表
output/marketing_strategies.csv	营销策略表
figures/*.png	全部图表

参考文献

1. Kaggle: Mall Customer Segmentation Data.
2. MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations.
3. Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to cluster analysis.